

东华大学学报(自然科学版)
Journal of Donghua University(Natural Science)
ISSN 1671-0444,CN 31-1865/N

《东华大学学报(自然科学版)》网络首发论文

题目: 面向复杂地形的四足机器人 RL-MPC 分层运动控制方法研究
作者: 王留东, 李培波, 徐洋
DOI: 10.19886/j.cnki.dhdz.2025.0438
收稿日期: 2025-12-04
网络首发日期: 2026-04-14
引用格式: 王留东, 李培波, 徐洋. 面向复杂地形的四足机器人 RL-MPC 分层运动控制方法研究[J/OL]. 东华大学学报(自然科学版).
<https://doi.org/10.19886/j.cnki.dhdz.2025.0438>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

面向复杂地形的四足机器人 RL-MPC 分层运动控制方法研究

王留东^{1a}, 李培波^{1a}, 徐 洋^{1a}

(1. 东华大学 a. 机械工程学院, 上海)

✉通信作者 李培波, 男, 职称, 副教授, 研究方向为移动机器人的运动控制和路径规划, E-mail: leonlee@dhu.edu.cn

摘要 实现不同复杂地形的稳定行走是四足机器人最具挑战性的任务之一。传统的基于模型的方法承受着建模复杂性的负担, 并且缺乏泛化能力。为解决上述问题, 提出一种融合模型预测控制 (MPC) 与强化学习 (RL) 的四足机器人分层运动控制框架, 有效解决传统 MPC 方法因模型简化导致的动态性能局限。其中分层控制架构: 上层通过强化学习策略实时优化 MPC 权重系数矩阵, 下层采用 MPC 执行高精度足端轨迹跟踪。通过引入域随机化技术构建多样化训练场景, 并设计融合运动稳健性、能量效率等多目标奖励函数, 使学习策略能够动态调整 MPC 的步态参数空间, 实现从简化模型到真实机器人系统的动态补偿。试验结果表明, 相较于传统 MPC 方法, 所提框架在云深处 Lite3 机器人平台上实现了显著性能提升, 稳定后速度跟踪误差绝对值小于 0.1m/s, 姿态角误差绝对值低于 0.06rad。为四足机器人动态运动控制提供了模型驱动与数据驱动相融合的新范式, 在保证运动稳定性的前提下显著增强了系统对未知环境的适应能力。

关键词 模型预测控制, 强化学习, 分层控制, 域随机化, Sim2real

中图分类号 TP242.6

文献标志码 A

DOI: 10.19886/j.cnki.dhdz.2025.0438

Research on hierarchical RL-MPC motion control for quadruped robots in complex Terrains

WANG Liudong, LI Peibo, XU Yang

(College of Mechanical Engineering, Donghua University, Shanghai, China)

Abstract Achieving stable locomotion across complex terrains remains one of the most challenging tasks for quadruped robots. Conventional model-based approaches suffer from modeling complexity and limited generalization capabilities. To address these issues, this study proposes a hierarchical motion control framework for quadruped robots that integrates Model Predictive Control (MPC) with Reinforcement Learning (RL). This framework effectively overcomes the dynamic performance limitations caused by model simplification in traditional MPC methods. The hierarchical structure consists of an upper layer, where an RL strategy dynamically optimizes the MPC weight coefficient matrix in real time, and a lower layer, which employs MPC for high-precision foot-trajectory tracking. By incorporating domain randomization techniques to create diverse training scenarios and designing a multi-objective reward function that considers both motion stability and energy efficiency, the learned policy enables dynamic adjustment of the MPC gait parameter space, thereby compensating for discrepancies between simplified models and real-world robotic systems. Experimental results on the Deep Robotics Lite3 robot platform demonstrate substantial performance improvements over conventional MPC methods, with post-stabilization absolute velocity tracking errors below 0.1 m/s and absolute attitude angle errors under 0.06 rad. The proposed framework offers a novel paradigm combining model-driven and data-driven approaches, significantly enhancing the robot's adaptability to unknown environments while ensuring motion stability.

Key words model predictive control, reinforcement learning, hierarchical control, domain randomization, Sim2Real

四足机器人凭借其非结构化地形适应能力, 在灾害救援、野外勘探等领域展现出巨大应用潜力^[1,2]。然而, 动态运动控制始终面临模型不确定性与环境复杂性的双重挑战: 传统基于模型预测控

收稿日期: 2025-12-04

基金项目: 国家自然科学基金(52375528)

网络首发时间: 2026-04-14 12:10:14 网络首发地址: <https://link.cnki.net/urlid/31.1865.n.20260413.1713.001>

制 (MPC) 的方法^[3,4]依赖简化动力学假设^[5], 在复杂地形中易因建模误差累积导致运动失稳^[6]; 而端到端强化学习 (RL) 策略虽能通过数据驱动提升适应性, 却因策略黑箱特性引发安全可解释性争议^[7]。如何融合模型驱动与数据驱动的优势, 构建兼具高精度跟踪与自主决策能力的控制架构, 已成为学界亟待突破的关键问题。

四足机器人运动控制领域长期存在模型驱动与数据驱动方法的技术路线分歧。以模型预测控制为代表的基于简化动力学模型生成运动轨迹的方法, 在结构化环境中展现出高跟踪精度^[8]。但此类方法对足地接触动力学的高度简化 (如忽略地面形变与柔性关节效应), 导致其在非结构化地形中的运动稳健性显著下降^[9]。Kim 等^[10]提出了一种融合全身控制(WBC)和 MPC 的控制器, 该方法需对机器人运动学和动力学进行精确的建模和分析, 而灵活的控制设计需要繁琐的计算和手动参数整定^[11]。然而, 如何引入感知系统以提升运动协调性与落足精度, 仍是亟待解决的挑战。Jenelten 等^[12]在 ANYmal 机器人上部署融合感知与规划的控制方法, 通过在建立的高程图中搜索局部最佳立足点、优化接触力以防止滑移^[11,13], 提升了 ANYmal 在复杂地形^[14]的稳健性, 但机器人搭载的传感器数量和种类增加^[15,16], 严重降低控制器的求解速度。

为突破这一限制, 研究者尝试引入强化学习构建数据驱动的运动策略^[17,18]。例如, Tuomas 等^[19]通过仿真训练实现 Minitaur 机器人的动态步态控制, 但其端到端策略于真实部署时, 因未建模动力学效应而出现性能衰减。Hwangbo 等^[20]仅使用本体感知数据实现在复杂地形行走。此类依托物理反馈获取地形信息的方法存在固有局限性, Lee 等^[21]基于本体感知引入复杂地形课程学习以实现野外探索, Miki 等^[16]则在此基础上融合外部感知, 进一步优化控制性能。Hoeller 等^[22]提出的多层级框架中, 感知模块负责重建环境信息, 导航和运动模块负责保障跑酷运动基本能力, 但该框架的场景扩展性未充分验证; Jenelten 等^[23]提出融合轨迹优化与强化学习的混合控制架构, 依赖视觉感知训练以解决离散地形控制问题, 但一定程度上牺牲了腿足式机器人落足点灵活调整的优势。此外, 外部传感器的搭载不仅增加了机器人的硬件成本, 其识别效果还易受室外环境干扰。这一现象揭示了纯 RL 方法从仿真到现实 (Sim2Real) 迁移中的本质矛盾: 即策略在训练环境中的过拟合与物理参数辨识误差的耦合效应^[24]。

近年来, 融合 MPC 与 RL 的混合架构逐渐成为研究热点。这些方法的核心缺陷在于未建立动态参数耦合机制——MPC 的模型参数与 RL 的策略更新仍处于解耦状态, 难以实现实时环境扰动下的协同响应。与此同时, 仿真验证的可信度问题始终制约混合方法的理论发展。现有研究多依赖理想化仿真环境 (如平坦地形、无传感器噪声), 其结论^[25]仅对单一速度目标优化, 应与辅助目标人类偏好相结合。尽管域随机化^[26]技术被




图1 基于 Sim2real 与本体感知的 RL-MPC 分层机器人控制架构示意图
Fig. 1 Schematic Diagram of a Hierarchical Robot Control Architecture Integrating Sim2Real with Proprioceptive RL-MPC

证明可增强策略稳健性, 但针对四足机器人运动控制的多模态扰动建模 (如地形几何-动力学联

合随机化) 仍缺乏系统性研究。本文从三个层面突破现有研究局限: 1) 提出动态耦合的 MPC-RL 分层架构, 通过 RL 对 MPC 的状态参数空间进行非线性映射, 补偿预测控制中截断预测范围所导致的次优性, 从而改进策略; 2) 构建高保真仿真环境下的多目标联合训练机制, 在运动稳定性、能量效率与地形适应性之间实现最优控制; 3) 通过大规模域随机化, 增强强化学习策略的泛化能力, 并结合分层式 Sim2Real 迁移框架, 实现四足机器人在多种户外环境 (包括崎岖草地、砂石路面与斜坡地形) 中动态的稳健部署。

1 四足机器人控制系统

云深处 Lite3 机器人硬件系统如图 1 所示, 是一款面向科研应用的高性能四足机器人平台。其控制系统基于 Ubuntu 20.04 LTS 深度优化, 具备实时性, 支持 ROS2 Humble 及自研运动控制框架, 控制频率可达 1 kHz。机器人站立尺寸为长×宽×高 (700 mm×250 mm×400 mm), 整机质量 18 kg, 有效负载 7.5 kg。关节系统采用 12 自由度配置 (每条腿 3 个关节), 搭载云深处自研 J60 关节模块; 该模块集成无框力矩电动机、谐波减速器与绝对值编码器, 峰值扭矩可达 30 N·m。平台配备 IMU 惯性测量单元以获取实时姿态信息, 凭借自研关节技术、高实时性控制系统及开放模块化设计, 构建了高性能的科研开发支撑平台。



图 1 整体硬件系统描述
Fig.1 Overall hardware system description

2 RL-MPC 分层控制方法

2.1 分层控制框架

本框架采用分层控制架构, 上层强化学习策略通过控制指令以及本体感知计算状态空间的 MPC 权重矩阵, 生成权重矩阵参数优化指令, 下层模型预测控制基于动态调整后的参数执行高精度轨迹跟踪。具体设计如下:

1) 上层 RL 策略

本研究采用近端策略优化算法 (PPO), 将机器人当前状态与 MPC 权重系数输入神经网络, 输出更新后的权重系数矩阵和即时奖励。随后基于 MPC 求解各关节力矩, 驱动机器人完成状态更新; 再依据融合奖励与动作的目标函数, 迭代更新神经网络中的权重参数, 最终获得能够使累计奖励值最大化的最优动作决策。

2) 下层 MPC 控制器

如图 2 所示, 用户向机器人提供速度指令, 驱动的有限状态机决定步态计划, 在运动控制模块中, MPC 负责姿态脚的控制, 相比之下, 摆脚控制则决定了想要的脚位置, 利用雅可比矩阵将力指令 F 转换为关节力矩, 同时通过逆运动学将所需的足部位置映射到相应的关节角, 卡尔曼滤波器促进状态估计, 将本体感觉数据传递给运动控制和自适应行为策略。




图 2 MPC 控制框架
Fig.2 MPC control framework

为构建带有时变参数的优化问题，将连续时间状态方程转化二次型规划（QP）问题求解，基于简化的姿态动力学和平移动力学可以组合为以下形式：

$$\frac{d}{dt} \begin{bmatrix} \boldsymbol{\theta} \\ \mathbf{p} \\ \mathbf{w} \\ \dot{\mathbf{p}} \end{bmatrix} = \begin{bmatrix} 0_3 & 0_3 & \mathbf{R}_z(\psi) & 0_3 \\ 0_3 & 0_3 & 0_3 & \mathbf{I}_3 \\ 0_3 & 0_3 & 0_3 & 0_3 \\ 0_3 & 0_3 & 0_3 & 0_3 \end{bmatrix} \begin{bmatrix} \boldsymbol{\theta} \\ \mathbf{p} \\ \mathbf{w} \\ \dot{\mathbf{p}} \end{bmatrix} + \begin{bmatrix} 0_3 & \dots & 0_3 \\ 0_3 & \dots & 0_3 \\ \hat{\mathbf{I}}^{-1}[\mathbf{r}_1]_{\times} \dots \hat{\mathbf{I}}^{-1}[\mathbf{r}_n]_{\times} \\ \mathbf{I}_3/m \dots \mathbf{I}_3/m \end{bmatrix} \begin{bmatrix} \mathbf{F}_0 \\ \cdot \\ \cdot \\ \mathbf{F}_n \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \\ 0 \\ \mathbf{g} \end{bmatrix} \quad (1)$$

式中 $\boldsymbol{\theta}$ 为机器人的方向作为欧拉角 $[\phi, \theta, \psi]^T$ 的矢量， $\mathbf{R}_z(\psi)$ 是对应于偏航角 ψ 的旋转矩阵， $\mathbf{p}$ 和 $\dot{\mathbf{p}}$ 是机器人的质心位置和速度， $\mathbf{w}$ 是机器人的角速度， $\mathbf{r}_i$ 是机器人的质心位置到脚 i 的矢量， $\mathbf{F}_i$ 是腿 i 的地面反作用力， $\mathbf{I}$ 是惯量， m 为机器人的质量， $\mathbf{g}$ 为重力项。

用附加的重力状态重写将动力学置于状态空间形式中：

$$\dot{\mathbf{x}}(t) = \mathbf{A}_c(\psi)\mathbf{x}_c(t) + \mathbf{B}_c(\mathbf{r}_{1..n}, \psi)\mathbf{u}(t) \quad (2)$$

式中 $\mathbf{A}_c \in \mathbf{R}^{13 \times 13}$ 和 $\mathbf{B}_c \in \mathbf{R}^{13 \times 13}$ 。此形式仅取决于偏航和足迹位置，将动态变为线性时变适用于凸模型预测控制，然后将该公式离散化，并将其表述为^[8]中的 QP 问题，基于（2）中讨论的公式消除约束后公式可写为：

$$\mathbf{X} = \mathbf{A}_{qp}\mathbf{x}_0 + \mathbf{B}_{qp}\mathbf{U} \quad (3)$$

式中 $\mathbf{X} \in \mathbf{R}^{13k}$ 是预测时域期间的所有状态的向量， $\mathbf{A}_{qp}$ 是由连续系统离散化后，沿预测时域递推得到的初始状态传递矩阵， $\mathbf{B}_{qp}$ 是控制输入到未来状态的输入传递矩阵并且 $\mathbf{U} \in \mathbf{R}^{3nk}$ 是在预测时域期间的所有控制输入的向量。使与参考轨迹的加权最小二乘偏差和加权力大小最小化的目标函数为：

$$J(\mathbf{U}) = \|\mathbf{A}_{qp}\mathbf{x}_0 + \mathbf{B}_{qp}\mathbf{U} - \mathbf{x}_{ref}\|_L + \|\mathbf{U}\|_K \quad (4)$$

式中 $\mathbf{L} \in \mathbf{R}^{13k \times 13k}$ 是状态偏差的权值对角矩阵， $\mathbf{K} \in \mathbf{R}^{3nk \times 3nk}$ 是力大小的权值对角矩阵， $\mathbf{U}$ 和 $\mathbf{x}$ 是预测时域内所有控制输入和状态的向量， $\mathbf{K} = \alpha \mathbf{I}_{3nk}$ 选择相同的力权重。这个问题可以重写为：

$$\min_{\mathbf{U}} \quad \frac{1}{2} \mathbf{U}^T \mathbf{H} \mathbf{U} + \mathbf{U}^T \mathbf{G} \quad (5)$$

$$s.t. \quad \underline{\mathbf{c}} \leq \mathbf{C} \mathbf{U} \leq \bar{\mathbf{c}} \quad (6)$$

式中 $\mathbf{C}$ 是约束矩阵。

$$\mathbf{H} = 2(\mathbf{B}_{qp}^T \mathbf{L} \mathbf{B}_{qp} + \mathbf{K}) \quad (7)$$

$$\mathbf{G} = 2\mathbf{B}_{qp}^T \mathbf{L}(\mathbf{A}_{qp}\mathbf{x}_0 - \mathbf{y}) \quad (8)$$

式中 $\mathbf{y} = [x_{ref,1}, x_{ref,2}, \dots, x_{ref,k}]^T$ 是预测时域 k 步内，所有参考状态的堆叠所需的地面反作用力是 $\mathbf{U}$ 的前 $3n$ 个元素。注意， $\mathbf{H} \in \mathbf{R}^{3nk \times 3nk}$ 和 $\mathbf{G} \in \mathbf{R}^{3nk \times 1}$ 都不依赖于状态数，只依赖于脚数 n 和步长 k 。

2.2 动态调整机制

系统的核心在于构建创新的适应性行为策略，如表 1 所示，该算法的核心目标为：在基线 MPC 框架上增设上层强化学习（RL）策略，通过动态调整 MPC 框架中的权重矩阵，实现机器人自适应行为的同时，保障策略在不同机器人平台间的跨平台性能稳定性；本研究聚焦单机器人运动控制，策略的跨平台泛化性（即策略可适配不同硬件参数的单机器人（如 Unitree A1 及同类型号））通过域随机化训练中的机器人本体参数随机化（表 4）实现，无需额外修改控制架构。

表1 控制算法伪代码

Table 1 Pseudocode of control algorithm

Algorithm 1 RL-MPC Q Reflection	
1: Require: Command description I_{task} , coding MPC MPC , RL algorithm Γ , environment code M , fitness function AC , initial space P , State weight matrix Q	
2: Hyperparameters: iteration N , batch size K	
3: for N iterations do	
4: // State weight matrix from MPC	
5: $Q_1, \dots, Q_k \sim MPC(I_{\text{task}}, M, P)$	
6: // Train policies in simulation	
7: $\pi_1 = \Gamma(M, Q_1), \dots, \pi_k = \Gamma(M, Q_k)$	
8: // Evaluate policies in simulation	
9: $s_1 = AC(\pi_1), \dots, s_k = AC(\pi_k)$	
10: // Q reflection from RL	
11: $P := P :: \text{Reflection}(R_{\text{best}}^n, s_{\text{best}}^n)$	
where $\text{best} = \arg \max(s_1, s_2, \dots, s_k)$	
12: // Update best Q and policy	
13: if $s_{\text{best}}^n > s_{\text{RLMPC}}$	
$Q_{\text{RLMPC}}, \pi_{\text{initial}}, s_{\text{RLMPC}} = (Q_{\text{best}}^n, \pi_{\text{best}}^n, s_{\text{best}}^n)$	
14: Output: $Q_{\text{RLMPC}}, \pi_{\text{initial}}$	

算法 1 中 Reflection 机制是实现 RL 与 MPC 动态耦合的核心，其本质是通过 RL 策略学习“环境扰动-奖励反馈-权重调整”的映射关系，通过总奖励梯度定位 MPC 权重的优化方向，将模型简化偏差（如未建模的地面摩擦）转化为权重调整（如增大位置权重），实现控制性能补偿。动态补偿 MPC 简化模型导致的控制次优性。该策略通过处理观测空间中过去的命令、来自 MPC 期望命令的指令和权重系数，经过多层感知机（MLP）将观测空间中的参数映射到动作空间。

1) 观测空间

四足机器人的观测空间涵盖表征机器人实时状态的各项参数，筛选 48 维核心观测特征，经归一化、极端值裁剪、速度滤波预处理，稳定 RL 策略输入，保障 QP 求解过程与控制输出的连续性，上述参数均作为多层感知器（MLP）的输入变量，观测空间参数见表 2。

表2 观测空间参数

Table 2 Observation space parameters

Observation	Dimensions	Observation	Dimensions
COM position	3	DOF position	12
COM velocity	3	DOF velocity	12
COM Euler angle	3	Actions	12
COM angular vel	3	Total	48

2) 动作空间

观测空间的各项参数输入至 MLP 输入层后，输入信号经连接权重传递至隐藏层神经元，隐藏层中每个神经元均对输入层传入的所有信号完成加权求和，将所得结果通过激活函数完成非线性变换；

经上述处理后，最后一层隐藏层的输出特征将进一步传递至输出层。为保证输出层动作空间的稳定性，输出层用 Softplus 激活函数，确保权重平滑且始终为正，避免权重出现阶跃式突变，在输出后增加权重裁剪，避免权重过大或过小导致 MPC 求解异常，经输出层运算处理后，所输出的参数值即对应四足机器人的动作空间参数，具体如表 3 所示。

表3 动作空间参数
Table 3 Action space parameters

Action Space weights	Position	Velocity	Euler Angle	Angle vel	Total
Dimensions	3	3	3	3	12

试验结果表明，基于 MPC 权重动态调整的自适应行为策略，能够在给定步态规划与速度指令下，学习得到综合力控制所需的 MPC 权重系数，并实现运动行为的多样化^[27]。该策略不仅具备动态适应性，更显著提升了机器人运动的敏捷性与稳健性；尤为重要的是，其可在不同机器人平台间实现良好的泛化性能，且无需手动整定域随机化参数。

2.3 训练策略设计

为提高强化学习策略的泛化能力与训练效率，本文设计了一套结合域随机化、多目标优化与课程学习的综合训练策略。在 NVIDIA Isaac Gym 仿真环境中，支持加载多种机器人描述文件，并提供正向运动学、正向动力学、碰撞检测等功能。采用分布式 PPO 算法并行训练 4096 个环境实例，每个实例独立采样动力学参数与地形扰动，以提高策略学习对未建模动态的稳健适应性。

1) 域随机化配置覆盖机器人本体动力学与环境交互参数，为了提高策略的稳健性，并促进模拟到真实的过程中，随机化的机器人身体和躯干的质量，机器人的质心，地面摩擦和恢复系数，关节级 PD 增益和初始关节位置等参数。各参数的随机化范围详见表 4。

表4 域随机化参数
Table 4 Domain randomization parameters

Parameters	Body Mass	Link Mass	CoM	Ground fric
Range[Min,Max]	[0.8,1.2]	[0.8,1.2]	[-0.1,0.1]	[0.2,2.75]
Unit	Kg	Kg	m	-

2) 多目标优化根据设计丰富的奖励函数，使机器人学习行为多样性，可以在不同的工况和干扰下更具鲁棒性。奖励函数的设计在 2.4 详细介绍。

3) 课程学习

为避免机器人因奖励函数中关节运动惩罚条款而陷入原地停滞的训练崩溃问题，本试验采用渐进式训练策略^[21]：以极小的关节运动惩罚系数启动训练，随后通过固定课程逐步提升该系数强度；同时随训练进程线性增加质量、摩擦力、运动强度等扰动的难度。试验还借鉴 Wu 等^[21]的地形课程思路，构建包含平面、楼梯、斜坡、碎石、波浪、离散障碍物 6 类地形的高度场图（图 3），200 个地形按 20×10 网格排列，每行对应同类型地形且难度递增，单个网格尺寸为 10 m×10 m。所有机器人均从最低难度级别、不同类型地形环境开始训练，地形等级动态调整：若机器人的线性跟踪奖励达到 80%，则提升地形等级；若无法在一个训练回合中通过半数地形，则降低地形等级。所有机器人均从最低难度级别、不同类型的地形环境启动训练，地形难度随训练进程动态调整：若机器人的线性跟踪奖励达到 80%，则提升地形等级；若无法在单个训练回合中通过半数地形，则降低地形等级。




图3 复合地形包含平面、楼梯、斜坡、碎石、波浪、离散障碍物地形
Fig.3 The complex terrain includes flat areas, stairs, slopes, gravel, waves, and discrete obstacles

2.4 奖励函数设计

在基于强化学习的运动控制中，奖励函数通常设计得较为复杂，核心功能涵盖引导策略完成目标任务与正向规范策略行为。本试验将奖励函数划分为任务奖励与辅助奖励两类：前者用于引导策略实现命令跟踪、维持良好姿态并保持期望的基座高度；后者则用于引导策略满足机器人物理约束，实现更平滑的控制输出，同时助力策略学习节能特性，为从仿真环境到真实机器人的有效迁移提供支撑。其中速度跟踪误差奖励设置如下：

$$R_{v_{xy}^{cmd}} = \exp\{-|\dot{v}_{xy} - v_{xy}^{cmd}|^2 / \sigma_{vxy}\} \quad (9)$$

式中 v_{xy} 和 v_{xy}^{cmd} 分别是基座坐标系下沿 x 、 y 轴的速度和命令速度。为保证机器人严格按照命令方向移动，设计偏航角奖励：

$$R_{w_z^{cmd}} = \exp\{-(w_z - w_z^{cmd}) / \sigma_{wz}\} \quad (10)$$

式中 w_z 和 w_z^{cmd} 分别是机器人的偏航角速度和命令偏航角速度。为了将机器人保持一定水平上，设计了一个奖励限制沿 z 轴的线速度：

$$R_{h_z^{cmd}} = (h_z - h_z^{target})^2 \quad (11)$$

式中 h_z 和 h_z^{target} 分别是机器人的质心高度和质心期望高度。为降低机器人能耗，设计一个能量奖励：

$$R_{energy} = \sum_{i=1}^{12} \|\tau_i \dot{q}_i\| t \quad (12)$$

式中 τ_i 是第 i 个关节转矩， $\dot{q}_i$ 是第 i 个关节速度， t 是一个步长时间。

$$R_{RaiBert} = \sum_{i=1}^4 |p_{foot-desired}^i - p_{foot-body}^i|^2 \quad (13)$$

式中 $p_{foot-desired}^i$ 是第 i 个脚的 *RaiBert* 启发式期望落脚位置， $p_{foot-body}^i$ 是第 i 个脚的落脚位置。

在 t 时刻的奖励函数被设计为保证机器人的速度跟踪，同时最小化能量成本，多目标奖励函数设计为加权求和形式：

$$R(t) = \sum_{k=1}^N w_k R_{target} \quad (14)$$

式中 w_k 是每个奖励项对应的权重因子， R_{target} 是对应的目标奖励函数。所有权重因子对策略性能的影响均至关重要，其中任务奖励项（如速度跟踪奖励）的权重占比最高。试验初始阶段基于平坦地

形完成权重参数配置,随后依据机器人在复杂地形中的运动表现,对部分权重参数进行小幅修正。鉴于四足机器人具备固有运动稳定性,权重参数整体未发生显著调整,最终选取一组最优权重参数应用于本文复杂地形的策略训练。

3 试验与结果

3.1 训练结果

训练过程在搭载 Intel Core i7 处理器与 NVIDIA GeForce GTX 4070 Ti Super 显卡的计算平台上完成。试验采用 4096 个机器人并行仿真训练,历经 15000 次迭代,总耗时仅 3 h。训练总奖励经求和处理后确保为正值,其变化趋势如图 4 所示,在 3000 次迭代后呈现稳步上升的特征。




图 4 训练过程累计奖励变化曲线
Fig.4 Cumulative reward change curve during training process

得益于 MPC 的初始姿态预测控制机制,前 1000 次迭代内的总奖励显著高于纯 RL 控制方案,有效降低了策略训练的试错时间成本,相同迭代时长条件下,纯 RL 控制方案因未引入动力学建模机制且未融合外部传感信息,训练所得控制策略性能表现欠佳,极端情况下机器人难以实现稳定行走,且易出现策略局部收敛问题。因此在 3.2 节的控制策略对比试验中,未将纯 RL 控制方案纳入试验对照组。

仿真验证阶段采用多维度可视化技术对训练结果进行量化分析。如图 5 所示,首先构建包含 20° 斜坡与 $10\text{ cm} \times 25\text{ cm}$ 的垂直阶梯的复合地形环境,通过描述运动轨迹的方式,直观呈现控制系统在非结构化地形中的动态响应特性。在相同时间步的空间位置对比中,该策略在目标位置跟踪任务中实现了平均约 2.3 个标准偏差的性能提升,相较于传统 MPC 算法,本研究提出的控制策略相较于基线方法展现出显著的性能优势。




图 5 机器人通过复合地形的控制策略对比试验

Fig.5 Comparative experiments on control strategies for robots navigating complex terrain

如图 6 中曲线记录机器人在 1m/s 的速度指令下通过图 5 中复合地形的速度跟踪, RL-MPC 通过复合地形的全程耗时 6.4 s (MPC 为 7.2 s, 缩短 11.1% 时间), 稳态速度误差 ± 0.05 m/s (MPC 为 ± 0.15 m/s); 尤其在斜坡-阶梯过渡段, RL-MPC 因 RL 动态调整 MPC 权重, 速度波动仅 0.1 m/s, 远低于 MPC 因模型未考虑地面坡度阻力导致速度波动为 0.32 m/s, 验证了分层架构的地形适配优势。在复合地形下, 改进 RL-MPC 策略比基线 MPC 优先启动, 并且跟踪性能明显优于基线, 弥补 MPC 简化运动学、动力学模型迁移实机的差异。




图 6 MPC 与 RL-MPC 策略机器人复合地形的速度跟踪性能对比

Fig.6 Speed tracking performance comparison of MPC and RL-MPC policy robots on complex terrain

为验证机身姿态是否稳定, 通过比较图 7 中曲线可知, 基线 MPC 的 Roll 角在 ± 0.06 rad 波动, 而改进后的方法始终保持在 ± 0.02 rad 附近, 最大值不超过 ± 0.04 rad。




图 7 MPC 与 RL-MPC 配置下机器人在命令速度下通过复合地形的翻滚角对比

Fig.7 Comparison of the roll angle of the robot passing through complex terrain at the commanded speed under MPC and RL-MPC configurations

图 8 中表示 Pitch 角在保证速度领先的前提下, 保证上下楼梯过程保持俯仰角稳定。




图 8 MPC 与 RL-MPC 配置下机器人在命令速度下通过复合地形的俯仰角对比

Fig.8 Comparison of the pitch angle of the robot passing through the composite terrain at the command speed under MPC and RL-MPC configurations

为进一步探究改进后的方法在速度跟踪上的准确性, 试验中不断改变命令速度。如图 9 中曲线所示, 在平坦地形环境下, 实时改变机器人速度时, RL-MPC 策略始终能保持在指令速度基线附近。由图 10 比较两者与指令速度的误差可见, 接收到指令后系统迅速保持稳定, 稳定后的速度误差均不超过 0.1 m/s,表明该策略相较于经典 MPC 优势更为明显。




图 9 机器人在实时改变运动速度下, MPC、RL-MPC 两种方法的速度跟踪效果对比

Fig.9 Comparison of speed tracking effects between MPC and RL-MPC methods when the robot is changing its movement speed in real time




图 10 机器人在实时改变运动速度下, MPC、RL-MPC 两种方法的速度跟踪误差对比

Fig.10 Comparison of speed tracking errors between MPC and RL-MPC methods when the robot is changing its movement speed in real time

3.2 仿真到现实的迁移

完成仿真策略训练后,最需要解决的问题是如何克服仿真到真实的差距^[28],将策略部署到实机。通过 RL 训练出的策略文件以标准 PyTorch 格式保存在 pt 文件中,需要链接 Libtorch 库,配置好与本机的通信后,植入训练好的策略,通过代码调用驱动机器人移动^[29]。

为避免真实设备损坏风险,采取仿真验证 (Sim2Sim),如图 11 所示,通过 UDP 协议实现 PyBullet 仿真平台与 C++控制程序的实时通信 (延迟<10ms),在虚拟场景中复现真实硬件的动力学特性,结合硬件实测数据的迭代优化,可将算法部署周期缩短 40%以上。




图 11 机器人 Sim2Sim 至 PyBullet 仿真环境验证

Fig.11 Verification of the robot Sim2Sim to PyBullet simulation environment

将经过仿真验证的运动控制代码移植到机器人的控制板上,结果表明,整体效果符合预期,为后续的真实机器人试验奠定了基础。

为验证所提 RL-MPC 分层控制架构的必要性,本研究同步开展纯 RL 控制方案的对照试验。在 3.1 节所述的目标复合地形中,纯 RL 控制方案经训练后仅能实现短距离行走,随即出现足端拖地现象,最终因姿态失稳跌倒。其核心缺陷在于缺乏 MPC 的模型约束机制,策略试错成本显著增加,难以完成全程稳定行走任务。反观本研究提出的 RL-MPC 分层架构,通过 MPC 的模型预测能力保障机器人基础行走稳定性,同时依托 RL 动态调整权重以适配复杂地形特征,最终可稳定完成全流程行走任务。为验证了 RL-MPC 框架在台阶地形的运动稳健性,如图 12 所示,盲爬楼梯基线方法与所提方法的对比,楼梯高度约为 13 cm。



(a) 基线 MPC
Baseline MPC



(b) 改进 RL-MPC
Improvement of RL-MPC

图 12 盲爬楼梯的 MPC 和 RL-MPC 的比较

Fig.12 Comparison of blind climbing stairs MPC and RL-MPC: (a) baseline MPC; (b) improvement of RL-MPC

基线模型预测控制方案（图 12(a)）难以适配未建模地形特征，易导致机器人足端发生卡滞。所提改进框架（图 12(b)）依托策略学习机制，可在足端即将接触或接触障碍物时实时调整落足轨迹与姿态，有效保障机器人运动稳定性，充分验证了本研究方法在自适应地形交互行为方面的有效性。

3.3 复杂地形上的行走试验

为了评估控制策略在复杂地形上的运动性能，机器人穿越了楼梯和非结构性草地，如图 13 所示。结果表明，机器人始终表现出优异的行走稳定性。相信此工作对推进四足机器人的运动能力有重大贡献。



图 13 多地形路面试验

Fig. 13 Multi-terrain road surface experiment

如图 14 所示，试验充分验证了机器人在高度变化显著的楼梯地形中，具备出色的运动控制能力与稳定性，不仅能自适应楼梯形态，更能通过有效规划足端轨迹保障上下楼梯过程的平衡与安全。




图 14 在 15*25 cm 楼梯地形上下试验
Fig.14 Experiment conducted on a 15*25 cm staircase terrain

这些试验结果表明机器人对楼梯类地形的高度适应性，也为后续机器人技术的发展与实际应用提供了重要参考。

4 总结与展望

在这项研究中，本工作提出了强化学习和模型预测控制的混合控制，提高了运动的敏捷性和稳健性。通过整合 MPC 的前瞻性预测和 RL 对过去经验的推理能力，改进 RL-MPC 框架揭示了机器人在穿越复杂景观和处理意外扰动方面的灵活性的显著提高。RL-MPC 融合框架可扩展至双足机器人、外骨骼等动态系统。下一步将基于实机平台，在野外非结构化地形中验证框架的零样本迁移能力，推动四足机器人从实验室走向实际应用。

参考文献

- [1] Hutter M, Gehring C, Jud D, et al. ANYmal - a highly mobile and dynamic quadrupedal robot [C]//2016 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Daejeon, Korea. IEEE, 2016: 38-44.
- [2] Raibert M, Blankespoor K, Nelson G, et al. BigDog, the rough-terrain quadruped robot [J]. IFAC Proceedings Volumes, 2008, 41(2): 10822-10825.
- [3] Dario Bellicoso C, Gehring C, Hwangbo J, et al. Perception-less terrain adaptation through whole body control and hierarchical optimization [C]//2016 IEEE-RAS 16th International Conference on Humanoid Robots (Humanoids). Cancun, Mexico. IEEE, 2016: 558-564.
- [4] Park H W, Wensing P, Kim S. Online planning for autonomous running jumps over obstacles in high-speed quadrupeds [C]//Robotics: Science and Systems XI. Robotics: Science and Systems Foundation, 2015. DOI:10.15607/rss.2015.xi.047.
- [5] Fankhauser P, Bjelonic M, Dario Bellicoso C, et al. Robust rough-terrain locomotion with a quadrupedal robot [C]//2018 IEEE International Conference on Robotics and Automation (ICRA). Brisbane, QLD, Australia. IEEE, 2018: 5761-5768.
- [6] Grandia R, Jenelten F, Yang S H, et al. Perceptive locomotion through nonlinear model-predictive control [J]. IEEE Transactions on Robotics, 2023, 39(5): 3402-3421.
- [7] Rudin C. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead [J]. Nature Machine Intelligence, 2019, 1(5): 206-215.
- [8] Di Carlo J, Wensing P M, Katz B, et al. Dynamic locomotion in the MIT cheetah 3 through convex model-predictive control [C]//2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Madrid, Spain. IEEE, 2018: 1-9.
- [9] Bellicoso C D, Jenelten F, Gehring C, et al. Dynamic locomotion through online nonlinear motion optimization for quadrupedal robots [J]. IEEE Robotics and Automation Letters, 2018, 3(3): 2261-2268.
- [10] Kim D, Di Carlo J, Katz B, et al. Highly dynamic quadruped locomotion via whole-body impulse control and model predictive control [PP/OL]. V1. arXiv (2019-09-14)[2026-01-15]. <https://doi.org/10.48550/arXiv.1909.06586>.
- [11] Katz B, Di Carlo J, Kim S. Mini cheetah: a platform for pushing the limits of dynamic quadruped control [C]//2019 International Conference on Robotics and Automation (ICRA). Montreal, QC, Canada. IEEE, 2019: 6295-6301.
- [12] Jenelten F, Miki T, Vijayan A E, et al. Perceptive locomotion in rough terrain—online foothold optimization [J]. IEEE Robotics and Automation Letters, 2020, 5(4): 5370-5376.
- [13] Gehring C, Bellicoso C D, Coros S, et al. Dynamic trotting on slopes for quadrupedal robots [C]//2015 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Hamburg, Germany. IEEE, 2015: 5129-5135.
- [14] Valsecchi G, Grandia R, Hutter M. Quadrupedal locomotion on uneven terrain with sensorized feet [J]. IEEE Robotics and Automation Letters, 2020, 5(2): 1548-1555.
- [15] Peng X B, Coumans E, Zhang T N, et al. Learning agile robotic locomotion skills by imitating animals [C]//Robotics: Science and Systems XVI. Robotics: Science and Systems Foundation, 2020. DOI:10.15607/rss.2020.xvi.064.
- [16] Miki T, Lee J, Hwangbo J, et al. Learning robust perceptive locomotion for quadrupedal robots in the wild [J]. Science Robotics, 2022, 7(62):

- cabk2822.
- [17] Rudin N, Hoeller D, Reist P, Hutter M. Learning to walk in minutes using massively parallel deep reinforcement learning [C]//Proceedings of the 5th Conference on Robot Learning. PMLR, 2022, 164: 91-100.
- [18] Li Z Y, Cheng X X, Peng X B, et al. Reinforcement learning for robust parameterized locomotion control of bipedal robots [C]//2021 IEEE International Conference on Robotics and Automation (ICRA). Xi'an, China. IEEE, 2021: 2811-2817.
- [19] Haarnoja T, Ha S, Zhou A, et al. Learning to walk via deep reinforcement learning [C]//Robotics: Science and Systems XV. Robotics: Science and Systems Foundation, 2019. DOI:10.15607/rss.2019.xv.011.
- [20] Hwangbo J, Lee J, Dosovitskiy A, et al. Learning agile and dynamic motor skills for legged robots [J]. Science Robotics, 2019, 4(26): eaau5872.
- [21] Lee J, Hwangbo J, Wellhausen L, et al. Learning quadrupedal locomotion over challenging terrain [J]. Science Robotics, 2020, 5(47): eabc5986.
- [22] Hoeller D, Rudin N, Sako D, et al. ANYmal parkour: Learning agile navigation for quadrupedal robots [J]. Science Robotics, 2024, 9(88): eadi7566.
- [23] Jenelten F, He J Z, Farshidian F, et al. DTC: deep tracking control [J]. Science Robotics, 2024, 9(86): eadh5401.
- [24] Ibarz J, Tan J, Finn C, et al. How to train your robot with deep reinforcement learning: lessons we have learned [J]. The International Journal of Robotics Research, 2021, 40(4/5): 698-721.
- [25] Margolis G B, Yang G, Paigwar K, et al. Rapid locomotion via reinforcement learning [J]. The International Journal of Robotics Research, 2024, 43(4): 572-587.
- [26] OpenAI, Akkaya I, Andrychowicz M, et al. Solving rubik's cube with a robot hand [PP/OL]. V1. arXiv (2019-10-16)[2026-01-15]. <https://doi.org/10.48550/arXiv.1910.07113>.
- [27] Margolis G B, Agrawal P. Walk these ways: tuning robot control for generalization with multiplicity of behavior [PP/OL]. V1. arXiv (2022-12-06)[2026-01-15]. <https://doi.org/10.48550/arXiv.2212.03238>.
- [28] Zhao W S, Queralta J P, Westerlund T. Sim-to-real transfer in deep reinforcement learning for robotics: a survey [C]//2020 IEEE Symposium Series on Computational Intelligence (SSCI). Canberra, ACT, Australia. IEEE, 2020: 737-744.
- [29] Tan J, Zhang T N, Coumans E, et al. Sim-to-real: learning agile locomotion for quadruped robots [C]//Robotics: Science and Systems XIV. Robotics: Science and Systems Foundation, 2018. DOI:10.15607/rss.2018.xiv.010.